



Diagnóstico da Saúde de Transformadores de Alta Potência via Ruídos de Magnetostricção com apoio de Drones Terrestres

Esta apresentação abordará o projeto de diagnóstico da saúde de transformadores de alta potência com o apoio de drone terrestre. Exploraremos como os ruídos de magnetostricção revelam a saúde dessas máquinas críticas e como o uso de drones aumenta o nível de segurança.



por Carlos Delfino

Quem é Carlos Delfino

- Profissional atuante a 35 anos no campo de TI;
- Desenvolvedor de softwares no backend e firmware;
- Atuou como técnico de manutenção em TI por 10 anos;
- Atuou como desenvolvedor por outros 10 anos;
- Estudou e atuou no campo de firmware por 15 anos;
- Formado como Técnico em Eletrônica por tempo de experiência;
- Formado tecnólogo em Projeto e Implementação de Redes de Computadores;
- Colaborador no Mestrado do Prof. Aminadabe - Diagnóstico de Falhas em Redes WDM/SDH
- Colaborador no Mestrado do Prof. Inácio Dutra - Diagnóstico com Agentes Móveis - Aglets



Transformador Explode em Fortaleza no Bairro do PICI



YouTube



Transformador Explode no Ca...

#cursogratico #eletronica Para
doações para ajudar na compra d...



g1 G1



Explosão em subestação de e...

Confira mais notícias em
g1.globo.com/ce



Como surgiu o Projeto "Magneto"

- O projeto surgiu com a necessidade de desenvolver uma solução em IoT para conclusão da primeira etapa do Embarcotech;
- Sugerida pelo Mstr. Eng. Davi Paiva, durante uma conversa sobre o Embarcotech, e consolidada pelo Eng. Francisco Santana;
- Como já atuei como assistente em dois mestrados sobre Diagnóstico, vi que seria totalmente coerente com minha experiência;
- O assunto acabou despertando meu anseio por aprendizado e conhecimento, influenciando na minha dedicação.
- Desde então tenho me dedicado a pesquisar sobre DSP (Digital Signal Processing) para análise de sinais utilizando filtros, cepstrais e redes neurais.



A Vital Importância dos Transformadores de Alta Potência e Seus Desafios



Distribuição de Energia

Transformadores são essenciais para a distribuição eficiente de eletricidade.



Desafios Operacionais

Falhas podem causar interrupções e grandes perdas financeiras. Além de causarem poluição sonora



Manutenção Preditiva

O diagnóstico precoce evita avarias e otimiza a manutenção. Trazendo economia e conforme em áreas urbanas, conforto.

Transformadores de alta potência são o coração das redes elétricas. Sua falha impacta diretamente o fornecimento e a economia. A manutenção preditiva é crucial para garantir a continuidade e segurança.

O Impacto Econômico e a Importância dos Transformadores na América Latina

O mercado de transformadores na América Latina é robusto e vital, com uma infraestrutura elétrica vasta e em constante expansão que depende diretamente desses equipamentos essenciais.



Mercado Bilionário

Valor estimado entre US\$ 2,9 e US\$ 5 bilhões (2024/2026), com crescimento sustentável projetado para a próxima década.



Cobertura Abrangente

Mais de 223 milhões de clientes conectados à rede, incluindo residências e indústrias, com eletrificação residencial quase universal.



Perdas Significativas

As perdas elétricas na distribuição, que incluem falhas em transformadores, chegam a cerca de 7,4% da energia injetada no Brasil, gerando bilhões em custos.


A confiabilidade e a eficiência dos transformadores são cruciais para a estabilidade econômica e o fornecimento contínuo de energia na região.

Entendendo a Magnetostricção: O Fenômeno Físico por Trás do Ruído

O Que é?

Magnetostricção é a alteração dimensional de materiais ferromagnéticos.

- Causada por campos magnéticos.
- Gera vibrações e ruídos.




No Transformador

O núcleo do transformador vibra com a magnetostricção.

- Sons específicos indicam anomalias como:
 - Falhas estruturais
 - Falhas nas bobinas
 - Sobrecarga
- Ajuda a detectar desgastes internos.

A magnetostricção é um fenômeno que ocorre no núcleo dos transformadores. Essa vibração gera ruídos que, quando analisados, revelam informações valiosas sobre o estado interno do equipamento.

O Ruído Como Indicador Preciso: Aplicações no Diagnóstico Preditivo



Os ruídos de magnetostricção são indicadores precisos de diversas falhas. Permitem o diagnóstico precoce de descargas parciais, superaquecimento e problemas mecânicos. Isso otimiza a manutenção e prolonga a vida útil dos transformadores.



Metodologias de Aquisição e Análise dos Ruídos de Magnetostricção



Sensores Acústicos e Acelerômetros

Microfones especiais captam os ruídos.



Drone Terrestres

Agilizam as coletas, trazem precisão e autonomia, além da segurança aos operadores. Também permitem a adição de outros métodos de diagnósticos



Digitalização de Dados

Sinais acústicos são convertidos em dados digitais.



Análise Espectral

Frequências e amplitudes são analisadas para padrões de frequências.



Inteligência Artificial

Algoritmos com apoio de redes neurais convolucionais identificam desvios e problemas, classificando o sinal.


Riscos Tecnológicos


Como todo projeto inovador que utiliza tecnologia de ponta, este está sujeito a riscos inerentes ao desconhecimento dos desafios que serão encontrados. A pesquisa é fundamental para identificar custos, possíveis falhas no projeto e implementar as correções necessárias.

Até o momento, não identificamos problemas significativos com as tecnologias escolhidas. No entanto, demanda-se a realização de mais testes para validar a robustez do sistema.

O rover representa o maior risco do projeto, pois torná-lo autônomo em um ambiente potencialmente hostil, com possíveis interferências eletromagnéticas, constitui um desafio técnico considerável.

A captura de amostras para treinamento do modelo também é um grande desafio, exigindo rigor metodológico e quantidade suficiente de dados para garantir a precisão do sistema.





Custos do Projeto

O projeto envolve tecnologia de ponta, que ainda está se difundindo no mercado. havendo pouca demanda e elevando o preço por unidade.

O Rover por sua vez representa o maior custo em torno de U\$ 30,000.00.

O sistema embarcado em si terá um **custo** em torno de **U\$ 300** mais o acoplador acústico. Valor para iniciar as pesquisas.

Já a mão de obra envolvida não temos ainda um projeção. portanto os custos de campo não estão definidos.



STM32N6570-DK

É um microcontrolador capaz de controlar o rover e analisar sinais para tomada de decisão em campo. No entanto, não substitui um computador de borda para análises em maior escala.

Lançado no segundo semestre de 2024, é um kit para prototipação e prova de conceito para uso de microcontroladores com redes neurais. Possui um microcontrolador STM32N6570 equipado com uma unidade de processamento neural (NPU) que permite executar redes neurais em sistemas embarcados. Oferece 4,5 MB de memória contínua e opera entre 600 MHz e 800 MHz de clock.

Valor no mercado internacional: **US\$ 237,00**

Uma unidade é capaz de processar dados coletados em uma subestação típica de uma indústria, pequena cidade ou bairro populoso de uma capital.

Steval Proteus 1

É uma ferramenta de precisão para uso industrial para coleta de vibrações e temperatura, baseado em SoC (System on Chip) wireless multiprotocolo na faixa dos 2.4GHz.

Alimentado por bateria. Comunica-se tanto com Bluetooth® Low Energy SIG specification v5.2, quanto com ZigBee 3.0.

Ideal para prototipação e provas de conceito onde se utiliza Aprendizado de Máquina e Redes Neurais para análise de vibrações;

Valor de Mercado **U\$ 50.00**

Uma unidade por Transformador




Sistema Acustico

A aplicação de sistemas acústicos com acopladores parabólicos, embarcados em rovers terrestres para a coleta de ruídos de magnetostrição em transformadores, representa uma proposta de alto potencial. No entanto, sua natureza ainda é experimental.

Para garantir a eficácia e a confiabilidade desta metodologia, são necessários testes rigorosos em campo. A validação do sistema exige comparações extensivas dos dados coletados por esta nova abordagem com metodologias de diagnóstico já estabelecidas, a fim de comprovar sua precisão e aplicabilidade em ambientes industriais reais.

O custo do acoplador é menor, porém ainda não identificado com precisão, mas também exige a necessidade do Microcontrolador principal que fará a pré análise dos sinais.




Tempo de Resposta das análises

O Tempo de resposta das análise no sistema embarcado ainda não foi mensurado com precisão;

Uma simulação feita em um computador Core i7 com 16GB de RAM e uma GPU RTX4060 o tempo girou em torno de alguns segundos por amostras de até 2 minutos. Já em um notebook Core i7 com 16GB de RAM não demonstrou grande diferença de desempenho.

Tais tempos não inclui o tempo de treinamento da rede neural, que não ultrapassa 5 minutos para 50 amostras, nos mesmos equipamentos.

Cada transformador leva em torno de 5 minutos entre captura e análise.



Emedded system analyeé .000 areer apre tois o
ste phers onu therpomeds's respronaces,
werwarre. confguration.

Métodos de Decomposição e Análise

- Realizamos testes com FFT, Cepstrais, ESPRIT, MUSIC e PRONY para decompor o sinal e transpor do domínio do tempo para o domínio da frequência.
- O método Cepstral superou a FFT em velocidade, demonstrando o melhor desempenho até o momento. No entanto, ainda precisamos validar se seu desempenho é aceitável em um microcontrolador STM32N6. Atualmente, é a melhor opção disponível.
- MUSIC (Multiple Signal Classification) oferece alta resolução e separa sinal de ruído, mas sobrecarregou significativamente a máquina e apresentou desempenho lento.
- ESPRIT (Estimation of Signal Parameters via Rotational Invariance Techniques) é computacionalmente mais rápido que MUSIC, porém ainda não obtivemos sucesso em sua implementação.
- PRONY (Método de Gaspard de Prony) é indicado para sinais transientes, como ao ligar o transformador ou durante imposição instantânea de altas cargas. Ainda não foi testado.

Método de Classificação

- Estamos usando uma rede convolucional (CNN - Convolutional Neural Network);
- Antamos pensando em usar Transforms também porém pode exigir maior poder computacional;
- Transforms pode vir a ser útil em visão computacional no futuro;



Banco de Amostras

Um banco de amostras bem selecionado é de extrema importância, porém propomos um método que viabiliza o aperfeiçoamento constante do modelo treinado. Esta proposta define o seguinte procedimento:

A cada novo transformador instalado se cadastra sua assinatura inicial que será a base de referência para seu período de vida e seriam classificados como "Equipamento Novo". Transformadores já instalados e recém revisados por métodos antigos também podem compor este banco de amostras. Estes seriam classificados como em "Equipamento em Bom Estado"

Com o início dos testes, pode se criar uma classificação para identificar os modelos que estão em "Em funcionamento", ou se já identificada uma falha, A classe seria qual for a falha.

Tal base poderá ser entendida para uso em outros clientes, poupando assim o período de treinamento inicial. Considerando os 184 municípios do estado do Ceará e 33 Regiões, contabilizando uma média de 1 transformador por município. teremos então 184 amostras iniciais classificadas como "Bom Estado"

Vantagens e Benefícios: Economia, Segurança e Confiabilidade Operacional

1

Redução de Custos

Economia com manutenção corretiva e paradas não programadas.

2

Segurança Aprimorada

Prevenção de falhas catastróficas e riscos à equipe.

3

Vida Útil Estendida

Aumento da longevidade dos equipamentos através de manutenção preventiva.

4

Redução de a Acidentes de trabalho

A redução dos riscos de acidente, caindo quase a 0% dos acidentes, contemplando requisitos da NR10 e outras NRs relacionadas

A aplicação dessa tecnologia traz benefícios significativos. Reduz custos de manutenção, aumenta a segurança operacional e prolonga a vida útil dos transformadores. A confiabilidade do sistema elétrico é drasticamente aprimorada.

SWOT ANALYSS



Analise SWOT

Forças

Equipe com expertise em software, infraestrutura de rede e sistemas embarcados. Experiência em correlações de falhas.

Posse do kit inicial para desenvolvimento com capacidade para redes neurais.

Fraquezas

Necessidade de **Engenheiro Elétrico** ou **Mecatrônico**

Custo de equipamentos é um desafio.

Em fase de pesquisa

Oportunidades

Expansão para novos mercados e aplicações.

Otimização contínua de algoritmos e hardware.

Ameaças

Concorrência com soluções já consolidadas.

Rápida evolução tecnológica exige adaptação constante.

Onde estamos no projeto

Fase Atual

Estamos em fase de levantamento de informações, ajustando nossa proposta e documentando referências.

Temos simulador em desenvolvimento para comprovar a viabilidade dos algoritmos

Posse do KIT inicial para teste do algoritmo em um Microcontrolador especializado

Simulador na Primeira Versão

Desenvolvemos um simulador que valida o uso dos ruídos de magnetostrição para diagnóstico e manutenção preditiva, um marco, pois constata que podemos sim usar tais ruídos para classificação com redes neurais.

Estamos Nos Preparando Para a Aquisição de Dados Reais

Iniciamos a fase de aquisição de dados reais em transformadores de alta potência, coletando informações cruciais para treinar e aprimorar nossos algoritmos de IA.



Conclusão: O Futuro da Manutenção Inteligente e Seus Próximos Passos

Integração em Redes

Conectividade com sistemas de gerenciamento de energia.

Previsão Avançada

Modelos preditivos mais sofisticados.

Manutenção Preditiva Autônoma

Drones Terrestres autônomos; Decisões automatizadas baseadas em dados.

Vibrometria a LASER

A vibrometria a LASER permite captar as vibrações do transformador sem haver influência dos ruídos ambientes

Análise em conjunto com Imagens Térmicas

Sensores Cognitivos para IoT

Sensores Cognitivos fazem uso de IA para ajustar seu método de coleta de dados, indo além do simples sensoriamento. Cognitive information centric sensor network (ICSN)



Lista Atualizada de Referências

1. **Torralba, A., Isola, P., Freeman, W.T.**
Foundations of Computer Vision.
MIT Press, 2024. ISBN: 9780262378666.
Série: *Adaptive Computation and Machine Learning series.*
Disponível em:
<https://mitpress.mit.edu/9780262048972/foundations-of-computer-vision/>
2. **Granados-Lieberman, D.; Huerta-Rosales, J.R.; Gonzalez-Cordoba, J.L.; Amezquita-Sanchez, J.P.; Valtierra-Rodriguez, M.; Camarena-Martinez, D.**
Time-Frequency Analysis and Neural Networks for Detecting Short-Circuited Turns in Transformers in Both Transient and Steady-State Regimes Using Vibration Signals.
Applied Sciences, 2023, **13**, 12218.
DOI: 10.3390/app132212218
3. **Bagheri, M.; Zollanvari, A.; Nezhivenko, S.**
Transformer Fault Condition Prognosis Using Vibration Signals Over Cloud Environment.
Departamento de Engenharia Elétrica e de Computação,
Nazarbayev University, Astana, Cazaquistão.
(Referência preliminar — aguarda complementação com dados editoriais)
1. **Wong, M.**
Neural Networks with Python.
Independently published, s.d.
(Referência provisória — aguarda confirmação de ano e editora)
2. **Rothberg, S., Allen, M.S., Castellini, P., Di Maio, D., Dirckx, J.J.J., Ewins, D.J., Halkon, B.J., et al.**
An International Review of Laser Doppler Vibrometry: Making Light Work of Vibration Measurement.
Optics and Lasers in Engineering, Volume 99, 2017, pp. 11–22.
DOI: [10.1016/j.optlaseng.2016.10.023](https://doi.org/10.1016/j.optlaseng.2016.10.023).
Publicado sob licença **CC BY-NC-ND 4.0**.
Repositório: <https://hdl.handle.net/2134/23115>
3. **Vibrômetro laser Doppler – Wikipédia, a enciclopédia livre.**
Disponível em:
https://pt.wikipedia.org/wiki/Vibrômetro_laser_Doppler.
Acesso em: junho de 2025.